	2101330_Talitha Syahla  Di sini saya memilih dataset kepadatan_penduduk dan persen_penduduk_trampil_tik, karena menurut saya kedua dataset tersebut memiliki hubungan yang kuat untuk memprediksi kategori_pmi. Dari kepadatan_penduduk dapat di bandingkan yang memiliki persen_penduduk_trampil_tik. Dari hasil perbandingan tersebut, dapat di klasifikasi kan dengan dataset kategori_pmi.
In [29]:	<pre>%matplotlib inline import numpy as np import pandas as pd import matplotlib.pyplot as plt import seaborn as sns</pre> Load Dataset
In [30]: Out[30]:	<pre>df = pd.read_csv("E:\\semester 3\\data mining\\dataset_UAS\\kepadatan_penduduk.csv") df.head(10)  prov tahun kepadatan_penduduk  0</pre>
	2 SUMATERA BARAT 2021 133 3 RIAU 2021 75 4 JAMBI 2021 72 5 SUMATERA SELATAN 2021 93 6 BENGKULU 2021 102
In [31]:	<pre>7  LAMPUNG 2021 262 8 KEP. BANGKA BELITUNG 2021 90 9  KEP. RIAU 2021 258  df1 = pd.read_csv("E:\\semester 3\\data mining\\dataset_UAS\\persen_penduduk_trampil_tik.csv") df1.head(10)</pre>
Out[31]:	tahun         persen_penduduk_trampil_tik         prov           0         2021         60.21         ACEH           1         2021         67.41         SUMATERA UTARA           2         2021         68.00         SUMATERA BARAT           3         2021         70.69         RIAU
	4         2021         64.47         JAMBI           5         2021         62.59         SUMATERA SELATAN           6         2021         62.10         BENGKULU           7         2021         65.76         LAMPUNG           8         2021         66.33         KEP. BANGKA BELITUNG
In [32]: Out[32]:	9 2021 89.06 KEP.RIAU  df2 = pd.read_csv("E:\\semester 3\\data mining\\dataset_UAS\\pmi.csv")  df2.head(10)  prov tahun kategori_pmi  O ACEH 2022 TINGGI
	1         SUMATERA UTARA         2022         TINGGI           2         SUMATERA BARAT         2022         TINGGI           3         RIAU         2022         TINGGI           4         JAMBI         2022         TINGGI           5         SUMATERA SELATAN         2022         TINGGI
	6         BENGKULU         2022         TINGGI           7         LAMPUNG         2022         TINGGI           8         KEP. BANGKA BELITUNG         2022         TINGGI           9         KEP. RIAU         2022         TINGGI
In [33]:	Mengeksplorasi Dataset kepadatan_penduduk  df.info() <class 'pandas.core.frame.dataframe'=""> RangeIndex: 280 entries, 0 to 279 Data columns (total 3 columns):  # Column Non-Null Count Dtype</class>
	0 prov 280 non-null object 1 tahun 280 non-null int64 2 kepadatan_penduduk 280 non-null object dtypes: int64(1), object(2) memory usage: 6.7+ KB  Mengeksplorasi Dataset persen_penduduk_trampil_tik
In [34]:	<pre>df1.info()  <class 'pandas.core.frame.dataframe'=""> RangeIndex: 245 entries, 0 to 244 Data columns (total 3 columns):     # Column</class></pre>
In [35]:	1 persen_penduduk_trampil_tik 245 non-null float64 2 prov 245 non-null object dtypes: float64(1), int64(1), object(1) memory usage: 5.9+ KB  Mengeksplorasi Dataset kategori_pmi  df2.info()
	<pre><class 'pandas.core.frame.dataframe'=""> RangeIndex: 442 entries, 0 to 441 Data columns (total 3 columns): # Column Non-Null Count Dtype</class></pre>
	dtypes: int64(1), object(2) memory usage: 10.5+ KB  Mengecek data NaN pada dataframe kepadatan_penduduk, persen_penduduk_trampil_tik, dan kategori_pmi  df.isna().sum() prov 0
Out[36]: In [37]: Out[37]:	tahun 0 kepadatan_penduduk 0 dtype: int64  df1.isna().sum()  tahun 0 persen_penduduk_trampil_tik 0 prov 0
In [38]: Out[38]:	<pre>dtype: int64  df2.isna().sum()  prov     0 tahun     0 kategori_pmi     0 dtype: int64</pre>
In [39]:	Karena dari ketiga dataframe tersebut tidak ada data NaN di dalam nya, maka tidak perlu mengisi data NaN yang kosong  Merge Ketiga Dataset  df3 = pd.merge(df, df1, how="left", on=["prov", "tahun"]) df3.head(10)
Out[39]:	prov         tahun         kepadatan_penduduk         persen_penduduk_trampil_tik           0         ACEH         2021         92         60.21           1         SUMATERA UTARA         2021         205         67.41           2         SUMATERA BARAT         2021         133         68.00           3         RIAU         2021         75         70.69
	4         JAMBI         2021         72         64.47           5         SUMATERA SELATAN         2021         93         62.59           6         BENGKULU         2021         102         62.10           7         LAMPUNG         2021         262         65.76           8         KEP. BANGKA BELITUNG         2021         90         66.33
In [40]: Out[40]:	9
	1         SUMATERA UTARA         2021         205         67.41         TINGGI           2         SUMATERA BARAT         2021         133         68.00         TINGGI           3         RIAU         2021         75         70.69         TINGGI           4         JAMBI         2021         72         64.47         TINGGI           5         SUMATERA SELATAN         2021         93         62.59         TINGGI
	6 BENGKULU 2021 102 62.10 TINGGI 7 LAMPUNG 2021 262 65.76 SEDANG  Visualisasi Data  Dari countplot di bawah, dapat dilihat bahwa kategori pmi didominasi oleh tingkat sedang, dimana tingkat sedang ini < 70
In [41]: Out[41]:	<pre>sns.countplot(x ="kategori_pmi", data=df4)  <axessubplot:xlabel='kategori_pmi', ylabel="count">  160 140</axessubplot:xlabel='kategori_pmi',></pre>
	120 - 100 - 100 - 80 - 40 - 20 -
In [42]:	Dari catplot di bawah, terlihat bahwa kategori_pmi memiliki tingkat yang senada pada tiap tahunnya dan pada setiap provinsi  sns.catplot(x="kategori_pmi", y="tahun", hue="prov", data=df4, height=8)
Out[42]:	<pre></pre>
	SUMATERA SELATAN  BENGKULU  LAMPUNG  KEP. BANGKA BELITUNG  KEP. RIAU  DKI JAKARTA  JAWA BARAT  JAWA TENGAH  DI YOGYAKARTA
	2016 - JAWA TIMUR BANTEN BALI NUSA TENGGARA BARAT NUSA TENGGARA TIMUR KALIMANTAN BARAT KALIMANTAN TENGAH KALIMANTAN SELATAN KALIMANTAN TIMUR
	KALIMANTAN UTARA SULAWESI UTARA SULAWESI TENGAH SULAWESI SELATAN SULAWESI TENGGARA GORONTALO SULAWESI BARAT MALUKU MALUKU UTARA PAPUA BARAT
In [43]:	tingkat persen trampil TIK disetiap provinsi memiliki beragam tingkat kategori_pmi, namun didominasi oleh tingkat tinggi sns.catplot(x="kategori_pmi", y="persen_penduduk_trampil_tik", hue="prov", data=df4, height=8)
Out[43]:	<pre></pre>
	SUMATERA SELATAN BENGKULU LAMPUNG KEP. BANGKA BELITUNG KEP. RIAU DKI JAKARTA JAWA BARAT JAWA TENGAH DI YOGYAKARTA
	JAWA TIMUR BANTEN BALI NUSA TENGGARA BARAT NUSA TENGGARA TIMUR KALIMANTAN BARAT KALIMANTAN SELATAN KALIMANTAN TIMUR KALIMANTAN UTARA
	SULAWESI UTARA SULAWESI TENGAH SULAWESI SELATAN SULAWESI TENGGARA GORONTALO SULAWESI BARAT MALUKU MALUKU MALUKU UTARA PAPUA BARAT PAPUA
	TINGGI SEDANG SANGAT TINGGI SANGAT RENDAH INDONESIA  Klasifikasi  Import Library
In [44]:	<pre>from sklearn.model_selection import train_test_split from sklearn.naive_bayes import GaussianNB from sklearn.metrics import classification_report from sklearn.metrics import accuracy_score from sklearn import tree from sklearn.ensemble import RandomForestClassifier from sklearn.metrics import confusion_matrix from sklearn.model_selection import cross_val_score</pre>
In [45]:	<pre>from sklearn.metrics import make_scorer from sklearn import preprocessing from sklearn.decomposition import PCA  from sklearn import preprocessing le = preprocessing.LabelEncoder() le.fit(df4.kategori_pmi) Y = le.transform(df4.kategori_pmi)</pre>
	<pre>list(le.classes_) ['SANGAT RENDAH', 'SANGAT TINGGI', 'TINGGI', nan]  X = df4.drop(["kategori_pmi"],axis=1)</pre>
	<pre>X_train, X_test, Y_train, Y_test=train_test_split(X, Y, test_size=0.2, random_state=None)</pre> <pre>Metode Decision Tree</pre>
ın [49]:	<pre>clf = tree.DecisionTreeClassifier() clf.fit(X_train, Y_train) Y_pred = clf.predict(X_test) acc = accuracy_score(Y_test, Y_pred) print("Akurasi {}".format(acc)) print(classification_report(Y_test, Y_pred))</pre>
	<pre>Input In [49], in <cell 2="" line:="">()         1 clf = tree.DecisionTreeClassifier()&gt; 2 clf.fit(X_train, Y_train)         3 Y_pred = clf.predict(X_test)         4 acc = accuracy_score(Y_test, Y_pred)  File ~\anaconda3\lib\site-packages\sklearn\tree\_classes.py:937, in DecisionTreeClassifier.fit(self, X, y, sample_weight, check_input, X_idx_sorted)         899 def fit(</cell></pre>
	<pre>900</pre>
	938
	163 check_X_params = dict(dtype=DTYPE, accept_sparse="csc") 164 check_y_params = dict(ensure_2d=False, dtype=None) > 165 X, y = selfvalidate_data(  166
	<pre>572 if validate_separately: 573  # We need this because some estimators validate X and y 574  # separately, and in general, separately calling check_array() 575  # on X and y isn't equivalent to just calling check_X_y() 576  # :( 577  check_X_params, check_y_params = validate_separately&gt; 578  X = check_array(X, **check_X_params) 579  y = check_array(y, **check_y_params)</pre>
	File ~\anaconda3\lib\site-packages\sklearn\utils\validation.py:746, in check_array(array, accept_sparse, accept_large_sparse, dtype, order, copy, force_all_finite, ensure_2d, allow _nd, ensure_min_samples, ensure_min_features, estimator)  744
	"Complex data not supported\n".format(array) 750 ) from complex_warning  File ~\anaconda3\lib\site-packages\pandas\core\generic.py:2064, in NDFramearray(self, dtype) 2063 defarray(self, dtype: npt.DTypeLike   None = None) -> np.ndarray: -> 2064    return np.asarray(selfvalues, dtype=dtype)  ValueError: could not convert string to float: 'KEP. RIAU'
In [50]:	<pre>Metode Random Forest  clf = RandomForestClassifier(n_estimators=100, random_state=123)     clf.fit(X_train, Y_train)     Y_pred = clf.predict(X_test)     acc = accuracy_score(Y_test, Y_pred)     print("Akurasi {}".format(acc))</pre>
	<pre>print(classification_report(Y_test, Y_pred)) </pre>
	<pre>File ~\anaconda3\lib\site-packages\sklearn\ensemble\_forest.py:327, in BaseForest.fit(self, X, y, sample_weight)     325 if issparse(y):     326     raise ValueError("sparse multilabel-indicator for y is not supported.")&gt; 327 X, y = selfvalidate_data(</pre>
	<pre>sample_weight = _check_sample_weight(sample_weight, X)</pre> File ~\anaconda3\lib\site-packages\sklearn\base.py:581, in BaseEstimatorvalidate_data(self, X, y, reset, validate_separately, **check_params)  579
	File ~\anaconda3\lib\site-packages\sklearn\utils\validation.py:964, in check_X_y(X, y, accept_sparse, accept_large_sparse, dtype, order, copy, force_all_finite, ensure_2d, allow_n d, multi_output, ensure_min_samples, ensure_min_features, y_numeric, estimator) 961 if y is None: 962    raise ValueError("y cannot be None")> 964 X = check_array( 965    X, 966    accept_sparse=accept_sparse, 967    accept_sparse=accept_large_sparse, 968    dtype=dtype,
	order=order, copy=copy, force_all_finite=force_all_finite, ensure_2d=ensure_2d, allow_nd=allow_nd, ensure_min_samples=ensure_min_samples, ensure_min_features=ensure_min_features, estimator=estimator,
	977 ) 979 y = _check_y(y, multi_output=multi_output, y_numeric=y_numeric) 981 check_consistent_length(X, y)  File ~\anaconda3\lib\site-packages\sklearn\utils\validation.py:746, in check_array(array, accept_sparse, accept_large_sparse, dtype, order, copy, force_all_finite, ensure_2d, allow _nd, ensure_min_samples, ensure_min_features, estimator) 744
	747 except ComplexWarning as complex_warning: 748     raise ValueError( 749
In [51]:	<pre>ValueError: could not convert string to float: 'KEP. RIAU'  Metode XGBoost  import xgboost as xgb from xgboost import XGBClassifier clf=XGBClassifier(seed = 20, max_depth=10, learning_rate=0.1, n_estimators=100,</pre>
	<pre>objective='binary:logistic', booster='dart', colsample_bytree = 0.7,</pre>
	<pre>print(classification_report(Y_test, Y_pred)) </pre>
	objective='binary:logistic', booster='dart', colsample_bytree = 0.7, colsample_bylevel = 0.8, colsample_bynode = 0.8, normalize_type = 'forest', sample_type = 'weighted', sampling_method = 'gradient_based')  ModuleNotFoundError: No module named 'xgboost'